构型概率分布的学习与生成：文献调研

2026-10-22

Contents

从构型概率分布学习到大体系采样：水、非晶与聚合物调研 **1**
1. 本项目究竟学习什么 . . . 1
2. 已发表或公开的工作做到哪一步 . . . 2
2.1 非晶：分布学习、潜空间与大尺度生成 . . . 2
2.2 水：必须区分单珠冰、显式水与量子 beads . . . 2
2.3 聚合物：局部条件重建具有迁移性，但需要 CG 输入 . . . 3
3. 尺度与物理含义的统一比较 . . . 3
4. 公开代码与预训练权重核查 . . . 4
5. “实验反演”与“生成分布”的相邻工作 . . . 4
6. 对 Gen_X 的选择建议与当前验证边界 . . . 4

机器学习势、运行环境与复用边界 **5**
势是否需要重训 . . . 5
可用水势 . . . 5
本机已观察到的能力 . . . 6
运行状态分层 . . . 6

从构型概率分布学习到大体系采样：水、非晶与聚合物调研

核查日期：2026-10-22。本文依据论文原文、作者页面和官方代码仓库整理；区分正式发表、预印本、公开代码与本项目实际验证。论文的性能数字均为作者报告，尚不构成本项目的复现结果。

1.本项目究竟学习什么

本项目的核心可以表述为：从已有构型或物理约束中学习一个分布，再从该分布生成新的原子构型。令X 表示周期性盒中的原子位置、元素和必要的分子拓扑，c 表示温度、密度、组成、制备条件或粗粒化结构，目标是建立

$$X \sim q_\theta(X \mid c).$$

这与训练机器学习势有区别。势模型学习$U_\phi(X)$ 以及$F_\phi(X) = -\nabla_X U_\phi(X)$，回答一个给定构型的能量与力；生成模型回答如何产生具有某种统计规律的构型。经典势或机器学习势都可以负责生产训练数据、提供能量约束、筛除不合理构型或执行后续弛豫。已有生成模型并不都使用机器学习势。

对于平衡液体，理想目标可以是给定势与热力学条件下的 Boltzmann 分布；对于玻璃，训练数据通常来自特定熔融—淬火或退火流程，学习的是依赖制备历史的结构分布。后者不能仅凭 RDF 相近，就认定为严格、无偏的热平衡采样。生成独立随机样本，也不自动保证其权重正确。

潜空间压缩是可选设计。扩散模型可直接对原子坐标加噪、去噪；normalizing flow 可在坐标或刚体位置／取向上建立可逆映射；backmapping 则以粗粒化构型为条件恢复原子细节。它们都可能包含神经网络隐特征，但不必先把整个小体系压成一个低维向量，再“放大”为大体系。尺寸迁移更依赖局部表示、周期边界处理、分子约束与独立验证。

2. 已发表或公开的工作做到哪一步

工作	发表状态与标识	核心对象
DM2，Yang 与 Schwalbe-Koda	npj Computational Materials 12, 29 (2026)；2025-12-10 在线发表；DOI	SiO_2 玻璃、CuZr 玻璃、实验非晶纳米粒子
GlassVAE，Chen 等	AAAI 40(1), 83–91 (2026)；2026-03-14 发表；DOI	金属玻璃结构生成与能量预测
Equivariant generative diffusion，Jiang 等	2026-10-02 预印本；arXiv:2610.03973	多组分非晶氧化物
Scalable Boltzmann generators，Schebek 等	Nature Communications 17, 5010 (2026)；DOI	mW 冰及其他晶态材料
Rigid Body Flows，Köhler 等	ICML 2023；PMLR 正式论文；arXiv:2301.11355	显式刚性水的冰 XI 相
GG-PI，Wang 等	2026-01-28 预印本；arXiv:2601.20228	液态水等体系的路径积分采样
AquaGen，Bengio 等	2026-07-03 预印本；arXiv:2607.03513	周期性显式水中的小分子溶质
DeepBackmap，Stieffenhofer 等	ML: Science and Technology 1, 045014 (2020)，DOI；APL Materials 9, 031107 (2021)，DOI	从粗粒化结构恢复聚合物原子构型

2.1 非晶：分布学习、潜空间与大尺度生成

GlassVAE 直接对应“编码到潜空间、再解码生成”的思路。该层级图 VAE 将原子构型编码为紧凑、具有平移和置换不变性的隐表示，再解码为新构型；训练引入 RDF 损失和能量回归损失，用于约束结构统计和能量相关性。这证明潜空间路线已有具体实例，但能量回归头不等于可以计算可靠原子力的 ML 势，紧凑编码也不自动带来跨尺寸解码。本次未核实其训练／生成原子数和公开权重，不将它写成任意尺寸生成方案。AAAI 正式论文摘要

DM2 有明确的小盒训练与大盒生成实例。SiO_2 训练数据来自 3000 原子的周期性 MD 盒，使用 Jakse 经典势；训练冷却率为 0.1、1、10、100 K/ps。模型采用 NequIP 式等变网络预测噪声位移，输入目标冷却率、组成和固定盒中的随机位置，输出非晶构型。论文生成的最大 SiO_2 结构为 112,848 原子，还展示 0.01 和 1000 K/ps 条件外推。这里的迁移对象包括尺寸和制备条件，而非先学习一个势能潜空间。DM2 正文与 Methods

其最终流程包括去噪后的 25 ps NVT 和 25 ps NPT 修整；SiO_2 与 CuZr 结果使用该步骤，实验纳米粒子生成没有该修整。CuZr 参考数据使用 EAM 势。因而应把最终质量归于“生成＋短 MD 修整”，并将学习目标理解为制备条件下的非晶分布。论文同时检验结构、力学性质和采样多样性，提供了比单一 RDF 更完整的评价范例。DM2 Methods 与验证

氧化物预印本进一步研究 DFT 数据驱动的条件生成。它使用局部等变网络，从随机坐标生成结构，可输入能量、密度等条件。训练数据包含零温弛豫构型、AIMD 快照和体积扰动构型；主要结构结果对应 8882 构型的 full 模型，1781 构型的 sparse 模型用于数据量研究。借用 NequIP ／ Graphite 网络骨架不意味着训练目标是能量或力，其主要任务仍是去噪。预印本 §2.1 与 Methods

该文报告 30 万原子的 GeO_2 生成耗时，但明确说明该次坐标未保留，只保留渲染，故它属于尺寸与计算成本证据。RDF 和配位数比较使用 3000 原子的已保存结构；不能表述为“30 万原子已验证 DFT 精度”，也不能把 1781 构型稀疏训练与 full 模型的大规模结果拼成同一实验。完整训练盒的原子数范围本次未核实，不用 360 ／ 720 原子的验证参考盒代替。预印本 §2.2，官方存档说明

2.2 水：必须区分单珠冰、显式水与量子 beads

Scalable Boltzmann generators 给出了清晰的尺寸外推。mW 立方冰模型在 216 个粒子上训练，应用到 512、1000、1728 个粒子。局部 GNN 驱动 normalizing flow，势能用于定义目标分布和训练；重要性权重用于统计校正。mW 把一个水分子表示为单个粒子，不包含氢和水分子取向。该证据支持局部生成映射

可迁移到更大晶态盒，但不证明同一模型可直接生成显式液态水。随着体系变大，作者报告有效样本比例下降，结构一致性与统计效率须分别评价。正式论文

Rigid Body Flows 处理显式水的位置与取向。论文实际冰 XI 实验使用 TIP4P-Ew 刚性水，体系为 16 或 128 个水分子，将 250 K 参考 MD 分布映射到 50 ／ 100 K 目标温度分布。该实验不是纯噪声直接生成液水，也未给出明确的小盒训练到大盒外推验证。它适合作为保持水分子几何约束、共同生成分子位置与旋转的架构参考。ICML 论文与 Appendix D

GG-PI 提供可直接检查的液态水权重。示例是 216 个 q-TIP4P/F 显式水分子、300 K、32 个路径积分 beads。模型用 flow matching 学习给定相邻 beads 的单 bead 条件分布，再通过 Gibbs 更新采样；水训练与验证都是 216 分子。32 个 beads 是同一物理体系的虚时间副本，不能把规模记成 6912 个独立物理水分子。其水训练采用受约束 MD，条件也不是目标 RDF。论文实验省略了可用于严格校正的 Metropolis 步骤，因此不能把数值吻合写成已经证明无偏。预印本 III.2 及附录

AquaGen 是显式水大体系生成的前沿实例。它用 OpenFF 2.1.1 与 TIP3P 经典力场 MD 数据训练 flow matching，从随机坐标和盒开始生成溶质、水及周期盒，条件包括溶质与炼金参数 λ；验证规模最高约 4000 个总原子。网络内部把 OHH 压为一个消息传递节点，随后恢复 H 的表示和输出，这属于计算优化，不是任意尺寸解码能力的证明。论文没有给出明确的小盒训练 → 任意大盒外推实验，且本次未确认公开官方权重。AquaGen 正文、Appendix A–B

2.3 聚合物：局部条件重建具有迁移性，但需要 CG 输入

DeepBackmap 学习的是给定粗粒化构型后的原子条件分布。2021 年工作将仅在辛烷和异丙苯液体上学到的局部相关性用于间规聚苯乙烯熔体，结合条件 GAN、逐原子重建与力场先验，输出包含氢的原子细节。参考模拟使用经典力场，不能将其称为 ML 势反演。作者论文页面，2021 论文原文

训练液体盒分别含 215 个辛烷分子和 265 个异丙苯分子；聚合物参考单帧含 36 条链、每链 10 个单体。论文所述测试 720 条链是累计测试量，不能理解成一个含 720 条链的大盒。该工作证明的是化学迁移与局部条件重建；大尺度链构象和堆积先由 CG 输入提供，不能直接替代从随机位置生成整个聚合物熔体。部分骨架角分布仍有偏差。2021 论文 §III–IV

3. 尺度与物理含义的统一比较

方法	训练或参考规模	已报告输出规模	不能据此推出的结论
DM2 ／ SiO_2	3000 原子 MD 盒	最大 112,848 原子	已获得严格平衡采样或任意实验冷却率的精确分布
氧化物扩散预印本	full 8882 构型；sparse 1781 构型；完整盒尺寸范围未核实	30 万原子耗时案例；3000 原子保存结构用于统计验证	30 万原子结构已完成 DFT 质量验证
Scalable BG ／ mW 冰	216 单珠粒子	1728 单珠粒子	已生成 1728 个带 H 的液态水分子
Rigid Body Flows	16 ／ 128 显式水的参考 MD	相同规模的目标冰分布	已证明液水或跨尺寸迁移
GG-PI ／水	216 显式水	216 水 ×32 虚时间 beads	6912 个独立物理水分子
AquaGen	多种溶质的显式水 MD 数据	约 4000 总原子	任意大水盒或纯水结构统计逆向设计
DeepBackmap	小分子液体局部环境	给定 CG 框架的 sPS 原子重建	从无结构噪声独立生成完整熔体拓扑

这些结果共同支持一种可检验的路线：学习局部构型分布或局部更新规则，再在更大周期盒中采样。但局部截断、长程相互作用、网络拓扑与有限尺寸效应决定其适用范围。尺寸增加后至少要复查能量、密度、RDF ／结构因子与材料特有结构指标；液水关注氢键和取向，玻璃关注配位、环和缺陷，聚合物关注链统计及穿链问题。

4. 公开代码与预训练权重核查

以下“存在权重”指官方仓库文件或作者说明已核实，不表示已在当前机器成功加载或复现。不同势、相态、组成及条件的权重不能直接互换。

方法	官方代码／入口	预训练权重状态	复用边界
DM2	DM2 官方仓库	有 SiO_2 条件／无条件、CuZr 模型	有训练与生成示例；项目网站不能替代程序仓库
GlassVAE	AAAI 论文入口	本次未核实	用于比较显式潜空间路线；尺寸迁移另行核查
氧化物扩散	dit-amorphous	有模型与部分结构结果	tag v1.1；公开生成路径，未公开训练管线及训练数据
Scalable BG	maxschebek/bgmat	有 216 粒子 mW 冰参数	晶相单珠模型，附教程
Rigid Body Flows	noegroup/rigid-flows	有 16 ／ 128 水实验权重	冰 XI 与原论文目标温度
GG-PI	官方仓库	有 water.pt 与示例数据	216 分子量子水示例，可检查 water.ipynb
AquaGen	论文	本次未确认公开权重	适合方法参考，暂不作为开箱起点
DeepBackmap	论文指向 mstieffe/deepBM	本次未确认	本次网页访问返回 404；须再次确认可用发行来源

已核实的示例权重路径如下，分别来自上述官方仓库：

- DM2：`gen-a-sio2-cond-v1.pt`、`gen-a-sio2-uncond-v1.pt`、`gen-cu50zr50-v1.pt`。
- bgmat：`tutorial/params_trained/params-mw_cubic_216.pkl`。
- rigid-flows：`experiments/ice_N128_T100/training_stage_0/epoch_9/model.eqx`。
- GG-PI：`checkpoints/water.pt`。

5. “实验反演”与“生成分布”的相邻工作

如果目标变为给定散射或 RDF 反推结构，EPSR 是应保留的传统基线。它用散射约束修正参考势并调整结构；但同样好的拟合可能对应不同先验和约束，不能据此宣称恢复了唯一原子构型或可靠的真实相互作用势。公开软件 Dissolve 提供相关结构精修能力。Soper，2001，Dissolve 方法论文

DiffTRe 展示了另一层逆问题：利用轨迹重加权，将结构和热力学目标用于优化势模型。其水示例是氧中心单珠粗粒化水，采用 DimeNet++，目标包括 RDF、角分布和压力。这里优化的是势参数，最终构型仍通过模拟采样；它与直接学习 $q_\theta(X \mid c)$ 互补。Thaler 与 Zavadlav，Nature Communications 12, 6884 (2021)

Han 与 Yu 进一步利用红外谱和密度细化 EANN 水势，并检验其他性质，说明实验数据可以改善物理评价器。它不等于已经具备从谱直接生成任意水盒的生成器。Nature Communications 16, 816 (2025)，作者代码

6.对 Gen_X 的选择建议与当前验证边界

第一起点建议选择 DM2 的公开 SiO_2 预训练模型。它与“学习构型分布、随机采样、再扩展尺寸”的目标最直接对应，已有代码、权重和相对完整的验证范式。先在小体系确认输入、生成、输出与分析流程，再讨论训练或尺度扩展；精确复现时应保留原势和生成后 MD 步骤。

如果优先关心尺寸迁移及可计算概率权重，可将 bgmat 的 mW 冰作为第二条对照路线；若必须使用显式液态水，可从 GG-PI 核对数据和采样代码，但应接受它针对量子采样的任务定义。氧化物预印本适合探索条件控制与 DFT 参考验证；其公开训练资源与最大尺寸证据均较有限。AquaGen 和 DeepBackmap 目前更适合作为架构与任务划分参考。

对水进行新的条件生成时，可考虑以分子中心和取向建模，显式保持分子几何与周期边界；若引入目标 RDF ／结构因子，应同时保留能量和高阶结构检验，避免只匹配二体统计。对玻璃，则优先保留密度、组成和制备条件标签，明确生成的是哪一类历史条件下的结构集合。

当前仓库工作的验收范围是 **CPU 环境中的 Bash ／ Slurm 冒烟测试**：检查配置读取、合成样例读取与几何 QA、周期边界、输出文件及候选队列是否接通。真实模型采样、完整 GPU 训练、大体系推断、原论文后处理和统计性能复现应作为后续独立验收。冒烟测试通过只能证明软件调度与数据流可运行，不能表述为已经复现论文的分布精度、加速比或尺寸泛化结论。

后续科学验收应在同一物理模型、条件和明确的样本预算下比较参考与生成集合。除均值外，记录分布宽度、异常构型比例、不同随机种子的变化，以及需要时的重要性权重和有效样本数。把去噪损失、结构统计、能量稳定性与目标性质分开记录，才能判断模型究竟学到了构型分布的哪些部分。

机器学习势、运行环境与复用边界

调研日期：2026-10-22。以下是网页、官方仓库和本机只读检查结果；权重未下载，推理兼容性未测试。

势是否需要重训

第一阶段冻结一个已有参考势，训练或复用生成器。这样才能区分生成器的分布误差与势本身的物理误差。仅当独立能量、力或目标条件下的物性验证失败，才考虑补充量化参考数据、微调势。生成器产生了高能结构，并不自动意味着势错了，也可能是生成器给出了不合理构型。

水有现成的复用依据。PNAS 2025的 *Computational investigation of water glasses using machine-learning potentials* 使用 DP_SCAN 和 DP_MBpol 研究低密度、高密度非晶冰，并未专门用非晶冰重新训练这两个模型。这支持先验证已有势，但不保证任意淬火路径和温压均准确。论文

可用水势

项目	已核实内容	使用边界
DNN@MB-pol	2023 水相图模型，2025 液—液临界点工作复用；DeePMD TensorFlow `.pb`；可接 LAMMPS	优先作为水路线的参考模型；新温压、淬火历史和核量子效应需分别验证
DP-SCAN	PRL 2021 水相图模型体系，PRL 2022 研究液—液相变	适合模型对照；参考泛函误差会改变温标和相界，不能直接将模型温压当实验真值
MACE-POLAR-1	通用分子模型，含长程静电与极化	原始论文水验证主要在 270–330 K、1 atm，报告密度及结构偏差；本轮不将其设为已验证的过冷水基准

DNN@MB-pol 的官方资源：

- 作者模型说明。
- 作者推荐的 graph-compress.pb，官方仓库条目约 36.9 MB。“compress”指运行时表格优化，不能理解成文件一定更小。
- 完整数据与模型归档，约 14.9 GB；推理不需要先下载整个归档。
- 2025 液—液相变论文。

DP-SCAN的官方资源：

- PRL 2022 正式数据归档。本轮其页面访问受限，未核实内部精确权重路径。
- 作者后续仓库中的同源 graph.pb；模型说明对应 PRL 126, 236001。本轮未将该文件与 2022 归档做二进制同一性验证。
- MACE-POLAR 原始论文。

“DNN@MB-pol”“DP_MBpol”“MB-pol(2023)”和其他基于 MB-pol 训练的模型不能只凭简称混用。最终每次运行必须保存：来源 URL、上游 commit、权重 SHA-256、类型映射、单位、截断、推理后端及版本。上面

DNN@MB-pol 归档标记为 `other-open`，未确认标准 MIT/GPL 许可证；可获得不等于可任意再分发，因此本仓库不打包上游权重。

本机已观察到的能力

检查项	观察结果	尚未验证
调度	`sbatch`、`squeue`、`sinfo`、`scontrol` 可用；用户确认使用 Slurm	GPU 任务本轮不提交
CPU smoke 资源	`debug` 分区可查询；按单 CPU、短 walltime 提交	每次执行时重新查资源，不承诺排队时间
GPU	集群列出 RTX4090 等 GPU 节点；用户说明 GPU 已满	不因节点显示 mixed 就认定 GPU 空闲
Python 基础环境	Python3.10、PyTorch2.12、ASE3.22、NumPy、SciPy、RDKit 可发现	不等于适配全部上游 checkpoint
DeepMD	工作区旁已有 CPU 及 CUDA 版 DeepMD3.2 环境和 `dp`/`lmp` 入口	尚未加载上述水模型
生成模型依赖	当前基础环境缺 e3nn、PyG、JAX 等	应为每条真实路线建立隔离环境并锁定版本
PDF 工具	Pandoc、XeLaTeX、中文字体可用	PDF 输出另做文本/页面检查

系统中 PBS 命令与 Slurm 共存，但本项目的作业脚本只用 Slurm。CPU smoke 使用 Python 标准库和共享目录，不涉及模型推理、训练、GPU 或节点本地 scratch。

运行状态分层

1. **文献核实**：作者报告了该方法和结果。
2. **入口 smoke**：配置、命令、日志和反馈队列能连通。
3. **模型推理**：实际加载指定权重并生成构型。
4. **分布验证**：结构、能量、相关统计和有效样本量满足基准。
5. **科学结论**：在独立证据及不确定性分析下支持物理判断。

这些层次不能互相替代。当前用户要求的执行上限为第 2 层；后续路线见技术路线文档。