bgmat 单珠水冰：真实生成示例与复跑教程

2026-10-22

Contents

bgmat：真正跑通的预训练构型生成 **1**
1. 生成了什么 . . . 1
2. 数据和证据 . . . 1
3. 如何复跑 . . . 2
4. 版本与实现边界 . . . 2
5. 调试记录和后续任务 . . . 3

bgmat：真正跑通的预训练构型生成

运行日期：2026-10-22。这个独立示例完成了**固定源码和权重 → 实际采样 → 坐标导出 → 基本验证**，与此前使用人工坐标的 synthetic smoke 分开记录。

1. 生成了什么

项目	实际结果
生成器	作者预训练 bgmat，可逆耦合流和局部图网络
已加载参数	7,972,860 个；不是随机初始化权重
物理模型与相态	mW 单珠水、立方冰；每个粒子代表一水分子，无显式 H
条件	200 K，数密度 0.033567184 Å^{-3}，边长约 18.600 Å
生成量	8 个不同构型，每个 216 粒子
后处理	只做周期坐标包装；没有能量最小化、MD、筛选或重采样
运行资源	2 CPU、8 GB 内存申请；没有申请或使用 GPU
Slurm	作业 96496，COMPLETED，退出码 0:0；总耗时 87 秒
模型推理	首个样本 21.37 秒，含 JIT；其后约 2.11–2.14 秒/样本

作业位于 `gpu` 分区的节点，但 `ReqTRES/AllocTRES` 均仅有 CPU、内存和节点，JAX 设备为 `TFRT_CPU_0`。原因是普通 CPU 分区满载，GPU 节点仍有空闲 CPU。分区名字不能用于判断是否申请了 GPU。

这说明**真实预训练生成流程可以执行**。它不等于已复现论文中的统计精度、尺寸外推或自由能结果，也不等于生成了常温液态水。

2. 数据和证据

- samples.extxyz：8 帧周期构型，可用 ASE 或结构可视化软件读取。`0` 是显示标签；计算质量密度时应按一个 mW 粒子对应一个水分子，而不是氧原子质量。

- samples.npz：坐标、盒子、能量、两类 log score 及重要性权重。
- samples.csv：逐构型能量、最短距离和权重。
- manifest.json：来源、运行条件、版本、参数数目、时间和输出哈希。
- 独立读取验证：数组形状、有限数值、PBC 范围、权重归一化及 extxyz 帧数检查。
- 采样日志、stderr、Slurm 记账与完整提交参数。

8 个样本的最短粒子间距为 2.343–2.418 Å，坐标、能量和 log score 均为有限值。归一化权重和为 1，有效样本数 ESS 约 3.53（44.09%）。这只是 8 个样本的诊断量，不能证明总体权重分布或热力学估计已收敛。

上游在物理坐标的高斯参考分布中省略了归一化常数，因此这里的模型和目标 log score 都采用作者的**非归一化、物理加辅助坐标联合空间约定**。归一化重要性权重中常数相消；不要把这些数组当作物理坐标边缘分布的绝对 log 概率。

原始生成样本平均能量为 −11.7722 kcal/mol/粒子；仓库提供的 1000 个 MD 参考样本均值为 −11.7487。两个数字仅供排错和量级核对，不将小样本均值接近视为分布验证。

3.如何复跑

从 Gen_X 根目录操作。先准备 Python 3.10，再运行：

```
bash tools/setup_bgmat.sh
```

若默认 Python 不是 3.10，设置 `GENX_PYTHON310` 为已有 Python 3.10 解释器路径。脚本只在项目内准备 `external/bgmat` 及 `.venv-bgmat`，按已保存的依赖锁文件安装，并验证源码和权重哈希。上游原始版本为 JAX/JAXlib 0.4.32；本次固定这一作者版本，不声称已验证新版兼容性。

准备一个新的日志目录和结果路径，然后提交 CPU 推理：

```
run_tag="bgmat_$(date -u +%Y%m%dT%H%M%SZ)"
mkdir "runs/${run_tag}_logs"
sbatch --parsable --partition=gpu \
  --job-name=genx_bgmat_real --nodes=1 --ntasks=1 \
  --cpus-per-task=2 --mem=8G --time=00:20:00 \
  --no-requeue --open-mode=append --export=NONE \
  --chdir="$PWD" \
  --output="$PWD/runs/${run_tag}_logs/slurm-%j.out" \
  --error="$PWD/runs/${run_tag}_logs/slurm-%j.err" \
  scripts/run_bgmat_cpu.sh --output "runs/$run_tag" --samples 8
```

此命令不包含 GPU GRES 请求；运行器还显式设置 `JAX_PLATFORMS=cpu`。如果集群不允许在 GPU 分区运行 CPU 作业，改成允许的 CPU 分区。必须从仓库根目录提交，输出路径不能已存在。更改种子可使用`--seed`；当前适配器只接受已验证的 216 粒子配置。

运行结束后同时检查 `sacct` 的终态和结果 manifest。加载权重、开始运行或出现首个样本日志，都不单独代表整个流程完成。

```
sacct -j < 实际作业号 > --format=JobID,State,ExitCode,Elapsed -P
python3 -m json.tool "runs/$run_tag/manifest.json"
```

4. 版本与实现边界

源码来自官方 bgmat 仓库，固定提交 `6e3db2b3453cb57eb16fdd2148c95ec35264faf4`。权重为作者的 `params-mw_cubic_216.pkl`，SHA-256 见 manifest 和源码常量。源码文件哈希另存 bgmat_source_lock.json，依赖见锁文件。

架构使用作者教程的 96 维 embedding、16 个局部邻居、10 层耦合流。适配器调用上游 `create_base`、`create_flow` 和 `_get_loss`；通过 `hk.transform(...).apply` 将真实预训练参数传入完整 flow。参考分布是在晶格附近加噪的分布，生成后的坐标来自训练好的变换，不直接把这些初始噪声坐标作为结果。

主要工程适配：Slurm 在 spool 目录执行脚本，项目路径改从 `SLURM_SUBMIT_DIR` 取得；计算节点不依赖 Git，用预先固定的源码哈希校验；上游 editable 安装未暴露 namespace 包，显式加入已校验源码路径。这些处理不更改模型权重或物理势。

5. 调试记录和后续任务

96462 在模型启动前因 Slurm 脚本路径失败；96471 因计算节点无 Git 失败；96484 取消以修正导入路径；96487 因 CPU 分区排队取消，改由 96496 以 CPU-only 方式运行。失败和取消记录均保留，只有 96496 报告实际生成成功。

软件测试现共 20 项通过，涵盖原 smoke 接口、生成输出、输入边界、源码校验及 Slurm spooled 脚本路径。与运行结果相结合，它们证明工程闭环，不替代科研验收。

后续可在这个独立项目中增加样本、多个种子、RDF 与高阶结构比较、权重收敛及尺寸迁移；另设非晶或全原子水项目。主动学习仍需要独立参考数据和触发准则，本示例没有自动训练生成器或势。