Gen_X 研究方案：非晶构型的概率分布迁移

2026-10-22

Contents

从工程示例到独立研究：非晶构型的概率分布迁移 **1**
1. 研究问题 . . . 1
2. 已有工作决定了什么不能当创新 . . . 1
3. 最小研究单元 . . . 2
4. 四步决策路线 . . . 2
   A. 先找出基线是否存在值得解决的缺口 . . . 2
   B. 建立可用的高精度参考，而非只选择一个模型名字 . . . 2
   C. 比较少数据迁移是否优于简单替代方案 . . . 2
   D. 检验改进能否跨尺寸保持 . . . 3
5. 反馈回环与停止标准 . . . 3
6. 当前成果与下一决策 . . . 3

从工程示例到独立研究：非晶构型的概率分布迁移

2026-10-22。状态：研究方案，不是已取得的科学结果。用户已认可“建立自己的课题，以高水平论文复现为对照”的方向。首个材料尚未最终确定；本文以非晶 SiO_2 给出可讨论的具体方案，非晶水与聚合物为替代分支。本轮不据此启动新训练或大规模计算。

1.研究问题

少量高精度小体系参考数据，能否修正生成器从经典力场数据继承的偏差，并将改进保持到更大体系的结构分布及独立性质中?

这里的“高精度”必须相对指定的电子结构参考和可验证物性定义。通用机器学习势、DFT 标签或神经网络架构本身都不自动构成高精度证明。生成结果服从什么参考模型、什么制备流程，必须在训练数据和结果中明确。

候选研究对象是制备历史条件下的玻璃构型分布。直接拿淬火后的结构套用平衡 Boltzmann 权重，不能保证得到正确的玻璃分布。迁移后的参考集合应来自目标势下、与基线匹配的制备协议；仅做 DFT 单点打分不足以提供完整的新构型分布。

2．已有工作决定了什么不能当创新

工作	已经展示的能力	本项目的角色
DM2，npj Computational Materials 12, 29 (2026)，2025 年在线发表	非晶 SiO_2 及金属玻璃生成，冷却条件、大尺度采样、结构与宏观性质验证	直接基线；不能把“大体系生成＋RDF ＋力学曲线”本身当新贡献
Scalable BG，Nature Communications 17, 5010 (2026)	mW 冰等体系的概率采样和尺寸迁移	工程及概率诊断对照；本地 8 构型示例不回答非晶研究问题
Equivariant generative diffusion…，2026 年预印本	从 DFT 来源构型学习非晶氧化物集合，并探索规模及条件变化	强近邻；说明“使用 DFT 数据训练非晶生成器”本身也不能称首次

工作	已经展示的能力	本项目的角色
MatterGen，Nature (2025)	无机晶体的条件生成与性质约束	方法参考；其晶体任务不能直接替代非晶基线

原始来源：DM2、DM2 官方代码、Scalable BG、氧化物预印本、MatterGen。这是一组代表性近邻，尚不是穷尽式新颖性检索。

因此，候选贡献应落在**数据效率、跨参考势迁移、独立性质可信度或可识别的失效边界**。若同类工作已经充分解决该问题，应调整假设，不能仅更换材料名称或网络名称。

3.最小研究单元

以 SiO_2 为候选，第一阶段固定化学组成与制备协议，只考察“参考势变化”和“体系尺寸”两个轴，不同时增加掺杂、变组成、裂纹、热输运和实验逆问题。

- **主要性质候选：体积模量及能量—体积响应。**必须统一温度、弛豫约束、应变幅度和拟合范围；先做数值收敛试验，再冻结测量协议。它比只看 RDF 更直接检验结构是否可用于性质计算。
- **结构诊断：**配位、Si—O—Si 角、环分布、结构因子及缺陷比例。采用明确的邻接与环定义，报告参数敏感性，不把任一种环算法的结果当唯一真值。
- **规模：**先在原作者公开设置下建立基线；再设计小盒高精度训练与大盒留出测试。所有预训练数据的尺寸都要披露，不能把已在 3000 原子经典数据上预训练的模型描述成“只见过 300 原子”。
- **独立参考：**与训练集分离的目标势轨迹、未参与调参的电子结构核验点；条件匹配时再加入实验。若评价势与生成引导势相同，需额外独立证据。

材料切换时，非晶水对应氢键网络与密度／响应性质；聚合物对应链拓扑、堆积及力学响应。它们的物理表示、制备协议和标签需求不同，不直接复用 SiO_2 的科学验收标准。

4. 四步决策路线

A. 先找出基线是否存在值得解决的缺口

复现 DM2 的公开同条件例子，保留原始生成与作者后处理后的两套结构。使用相同势、相同处理预算比较参考 MD 与生成集合，记录所有尝试及拒绝率。若没有可重复的结构或性质偏差，不预设其失败；转向其他留出条件或停止这个改进假设。

输出：基线运行包、样本和数据划分、结构／性质测量脚本、误差及统计区间、总成本账本。

B. 建立可用的高精度参考，而非只选择一个模型名字

核实目标势的来源、权重、训练覆盖、单位和应力定义。在独立代表构型上检查能量、力和需要的应力，并验证制备路径。若已有势达到标准，冻结它；否则先补充参考计算或微调势，再讨论生成器改进。

输出：目标参考势的验收记录、与基线相同制备协议下的小体系参考集合，以及严格留出的测试集合。没有这个参考，项目只能报告方法在某个模型上的行为，不能报告真实材料精度提升。

C. 比较少数据迁移是否优于简单替代方案

对照	要回答的问题
原始 DM2 及作者规定的后处理	原方法能达到什么水平?
原始 DM2 ＋同预算目标势弛豫／短 MD	改进是否只是换了后处理势?
同预算高精度数据从零训练生成器	预训练与迁移究竟节省了多少数据?
预训练生成器用高精度参考集合微调	分布迁移是否改善高阶结构和主要性质?
随机补样与覆盖／不确定性驱动补样	主动选点是否比增加同量随机数据更有效?

所有组使用相同目标数据预算、相同可比后处理预算和同一冻结测试集。分别报告裸生成、后处理、失败样本和参考计算的成本。学习曲线的数据量应按独立轨迹／构型集合统计，不能用高度相关的相邻帧夸大样本数。

输出：数据量—误差曲线、结构与性质联合评估、后处理消融，以及真实成本比较。先采用可控的微调基线；只有定位到明确不足后，才增加新的网络结构、引导项或层级模块。

D. 检验改进能否跨尺寸保持

冻结模型与阈值，在独立更大周期盒上生成多个种子的结构集合。检验中程关联、环及缺陷分布、能量—体积响应和主要性质。评价尺寸需越过所有相关预训练数据的范围，或明确标为已见尺寸上的参考势迁移。

如果大盒失败，应区分局部环境覆盖、周期表示、长程关联、目标势精度和参考采样不足。不能用延长 MD 修整掩盖生成器的问题；必要修整的成本必须计入。

5. 反馈回环与停止标准

生成器回环为：生成 → 找到可重复的分布缺口 → 补充独立参考样本 → 更新生成器 → 冻结测试回归。势的主动学习是另一条回环，只在独立误差或经校准的适用域信号表明有需要时启动。模型自己的低能打分不能证明其输出真实可靠。

值得继续的证据至少包括：相同数据预算下主要性质误差降低；高阶结构没有明显退化；结果跨种子与留出尺寸稳定；计入后处理和参考采样后仍有实际收益。

若优势完全来自后处理、只在训练附近存在，或目标势本身不能通过独立核验，就暂停大规模生成和论文叙事。负面结果也可以帮助定位方法边界，但不能预先包装成成功的材料发现。

6. 当前成果与下一决策

已经完成的是 bgmat 真实 CPU 推理和工程溯源；没有训练我们自己的生成器，没有证明高精度迁移，也没有完成非晶性质基线。本方案将这些层次分开。

下一决策是首个正式材料与主要性质。本文的 SiO_2 方案是明确的候选，尚未替用户确认材料。确认后首先执行 A 阶段的基线与缺口检查，而不是直接大规模训练。GPU ／ DFT 预算根据小规模实测和参考模型可用性再制定。